

Apuntes de EC2 Fundamentals

AWS Certified Solutions Architect – Associate (SAA-C03)

Basado en el curso de Stephane Maarek

Cómo leer estos apuntes

Los términos clave van en inglés porque así aparecen en el examen. Lo marcado con **[fuera del curso]** es conocimiento estándar de AWS que **no** aparece en las transcripciones del curso.

Índice

1. EC2 Basics	3
1.1. Qué es EC2	3
1.2. Qué se elige al lanzar una instancia	3
1.3. EC2 User Data (bootstrapping)	3
2. Security Groups & Classic Ports	3
2.1. Qué son	3
2.2. Comportamiento por defecto	3
2.3. Reglas de comportamiento	4
2.4. Referenciar Security Groups entre sí	4
2.5. Puertos clave para el examen	4
3. EC2 Instance Types	4
3.1. Naming convention	4
3.2. Las 4 familias del examen	5
3.3. Ejemplo de comparación (de la transcripción)	5
3.4. Recursos útiles	5
4. EC2 Instance Purchasing Options	6
4.1. On-Demand	6
4.2. Reserved Instances	6
4.3. Savings Plans	6
4.4. Spot Instances	6
4.5. Dedicated Hosts	6
4.6. Dedicated Instances	6
4.7. Capacity Reservations	7
4.8. Analogía del resort (del curso)	7
5. Spot Instances & Spot Fleet (deep dive)	7
5.1. Cómo funciona un Spot Instance	7
5.2. Spot Requests	7
5.3. Spot Fleet	8

5.4. Estrategias de asignación de Spot Fleet	8
6. Trampas de examen	8
7. Tus puntos débiles (repasar en Anki)	9
8. Vocabulario en inglés para tus respuestas	9

1. EC2 Basics

1.1 Qué es EC2

- **EC2 = Elastic Compute Cloud.** Servidores virtuales que “rentas” de AWS.
- Encarna la idea central del cloud: **rentar cómputo bajo demanda**, cuando lo necesitas.

1.2 Qué se elige al lanzar una instancia

- **Operating System (OS):** Linux (el más popular), Windows, o macOS.
- **Compute power:** cuánto CPU y cuántos cores.
- **RAM:** cuánta memoria.
- **Storage:** por **red** (EBS o EFS) o **hardware attached** (EC2 Instance Store).
- **Networking:** velocidad de la tarjeta de red y tipo de IP pública.
- **Security Group:** firewall de la instancia (Sección 2).
- **EC2 User Data:** script de arranque para configurar la instancia en el primer boot.

1.3 EC2 User Data (bootstrapping)

- **Bootstrapping** = lanzar comandos cuando la máquina arranca.
- El script **corre una sola vez**, en el primer arranque, y **nunca más**.
- Propósito: automatizar tareas de arranque – instalar updates, instalar software, descargar archivos de internet, o cualquier cosa necesaria.
- **Corre como root user**, así que cualquier comando tiene privilegios de **sudo**.
- Mientras más se agrega al User Data script, **más tarda la instancia en arrancar** (más tiempo leyendo y ejecutando el script).

Regla rápida

User Data = una sola vez, como root. No confundir con algo que se ejecuta en cada reinicio.

2. Security Groups & Classic Ports

2.1 Qué son

- El **firewall** alrededor de las instancias EC2.
- Controlan tráfico **inbound** (entrante) y **outbound** (saliente).
- **Solo tienen reglas “allow”.** No existe una regla “deny” dentro de un Security Group.
- Las reglas referencian **IPs** o **otros Security Groups**.
- Formato de regla: **type, protocol (TCP), port, source**. 0.0.0.0/0 = todo el mundo.

2.2 Comportamiento por defecto

- **Todo el inbound está bloqueado** por defecto.
- **Todo el outbound está permitido** por defecto.

2.3 Reglas de comportamiento

- Relación **muchos a muchos**: un Security Group puede estar en varias instancias, y una instancia puede tener varios Security Groups.
- Atados a la combinación **región/VPC**: cambiar de región obliga a recrear el Security Group.
- Viven **fuera** de la instancia EC2: si el tráfico es bloqueado, la instancia **ni lo ve**.
- Buena práctica: mantener un Security Group **separado solo para SSH**.

Diagnóstico de errores (examinable)

- **Timeout** (se queda esperando, nunca responde) → problema de **Security Group** (tráfico bloqueado).
- **“Connection refused”** → el Security Group **funcionó bien**; el tráfico llegó, pero la aplicación falló o no está corriendo.

2.4 Referenciar Security Groups entre sí

- En vez de autorizar por IP, un Security Group puede aceptar tráfico **proveniente de otro Security Group**.
- Así, las instancias se comunican sin importar sus IPs. Muy usado con Load Balancers.
- **Solo necesita la regla el que recibe la conexión** (inbound), no el que la inicia (su outbound ya está permitido por defecto).

2.5 Puertos clave para el examen

Puerto	Protocolo	Uso
22	SSH	Login a instancias Linux
22	SFTP	Transferencia segura de archivos (usa SSH)
21	FTP	Subir archivos a un file share
80	HTTP	Sitios web sin cifrar
443	HTTPS	Sitios web cifrados (estándar hoy)
3389	RDP	Login a instancias Windows

Truco de memoria

22 = SSH = Linux. 3389 = RDP = Windows.

3. EC2 Instance Types

3.1 Naming convention

Ejemplo: **m5.2xlarge**

- **M** = *instance class* (familia, ej. general purpose).
- **5** = *generación* del hardware (no “versión”). m5 → m6 al mejorar el hardware.
- **2xlarge** = tamaño dentro de la clase: small → large → 2xlarge → 4xlarge... Más tamaño = más memoria y más CPU.

3.2 Las 4 familias del examen

Familia	Para qué sirve	Casos de uso	Nombres
General Purpose	Balance entre compute, memoria y networking	Web servers, repositorios de código	T2 (free tier), M5
Compute Optimized	Tareas que exigen mucho CPU	Batch processing, media transcoding, HPC, machine learning, game servers dedicados	C5, C6
Memory Optimized	Procesar grandes datasets en RAM	DBs en memoria, cache distribuido (ElastiCache), BI, procesamiento en tiempo real	R (de RAM), X1, High Memory, Z1
Storage Optimized	Acceso rápido a datasets grandes en disco local	OLTP de alta frecuencia, NoSQL, cache (Redis), data warehousing, sistemas de archivos distribuidos	I, D, H1

Distinción clave

Memory Optimized = procesar en **RAM**. **Storage Optimized** = acceso rápido a **disco local**. Hadoop encaja en Storage Optimized porque necesita throughput de disco, no RAM masiva.

3.3 Ejemplo de comparación (de la transcripción)

- **t2.micro**: 1 vCPU, 1 GB RAM.
- **r5.16xlarge**: 16 vCPU, 512 GB RAM → mucho énfasis en memoria.
- **c5.4xlarge**: 16 vCPU, 32 GB RAM → menos memoria, más CPU relativo.

3.4 Recursos útiles

- Página oficial de tipos de instancia de AWS, para costos y specs actualizados.
- **ec2instances.info**: sitio de terceros para comparar instancias (costo On-Demand/Reserved, memoria, vCPU).

4. EC2 Instance Purchasing Options

4.1 On-Demand

- Pagas por uso: por **segundo** (Linux/Windows, tras el primer minuto) o por **hora** (otros OS).
- Costo más alto, pero **sin compromiso** de tiempo ni pago adelantado.
- Ideal para cargas **cortas e impredecibles**.

4.2 Reserved Instances

- Descuento de hasta **72 %** vs. On-Demand.
- Reservas atributos específicos: **instance type, región, tenancy, OS**.
- Periodo de **1 o 3 años** (más años = más descuento).
- Pago: **All / Partial / No upfront** (All upfront = máximo descuento).
- **Scope**: regional o zonal (AZ específica).
- Ideal para uso **steady-state** (ej. una base de datos).
- Se pueden **comprar o vender** en un marketplace.
- **Convertible Reserved Instances**: permiten cambiar instance type, family, OS, scope y tenancy. Descuento menor: hasta **66 %**.

4.3 Savings Plans

- Mismo descuento (~70 %) que Reserved, términos de 1 o 3 años.
- Compromiso: un **monto de gasto por hora** (ej. \$10/hora), no un instance type específico.
- Uso más allá del plan se cobra a precio On-Demand.
- Fijo en **familia de instancia y región**; flexible en **tamaño, OS y tenancy**.

4.4 Spot Instances

- Descuento más agresivo: hasta **90 %**.
- Se pueden perder **en cualquier momento** si el precio spot sube por encima del máximo definido.
- Ideal para cargas **resilientes a fallos**: batch jobs, data analysis, image processing.
- **No aptas** para trabajos críticos ni bases de datos.

4.5 Dedicated Hosts

- Reservas un **servidor físico completo**, dedicado a ti, con visibilidad del hardware.
- Casos de uso: **compliance/requisitos regulatorios**, o licencias **BYOL** (bring your own license) facturadas por socket/core/VM.
- On-Demand por segundo, o reservado 1–3 años.
- **La opción más cara** de AWS.

4.6 Dedicated Instances

- Corren en hardware dedicado a tu cuenta, pero puedes **compartir el hardware** con otras instancias propias.
- **Sin control** sobre el placement ni visibilidad del hardware físico.

Host vs. Instance

Dedicated Host = servidor físico completo, ves el hardware. **Dedicated Instance** = hardware dedicado a tu cuenta, sin esa visibilidad.

4.7 Capacity Reservations

- Reservas capacidad On-Demand en una **AZ específica**, por cualquier duración.
- **Sin descuento**: precio On-Demand, **se cobra aunque no lances instancias**.
- **Sin compromiso de tiempo**: se cancela cuando quieras.
- Para descuento, se combina con Reserved Instances regionales o Savings Plans.
- Ideal para cargas de corto plazo que **deben** estar en una AZ específica.

4.8 Analogía del resort (del curso)

- **On-Demand**: llegas cuando quieres, pagas precio completo.
- **Reserved**: sabes que te quedas mucho tiempo, reservas con anticipación y te dan buen precio.
- **Savings Plan**: “sé que voy a gastar \$300/mes en el hotel”, pero puedes cambiar de tipo de habitación.
- **Spot**: descuentos de última hora, pero te pueden sacar del cuarto si alguien paga más.
- **Dedicated Host**: reservas el edificio entero del resort.
- **Capacity Reservation**: reservas un cuarto sin saber si te vas a quedar, pero si quieres, ahí está (y lo pagas igual).

5. Spot Instances & Spot Fleet (deep dive)**5.1 Cómo funciona un Spot Instance**

- Defines un **max spot price** que estás dispuesto a pagar.
- Consigues la instancia mientras el **precio spot actual** esté por debajo de tu máximo.
- El precio spot varía por **oferta y capacidad**, y también **según la AZ** dentro de la misma región.
- Si el precio sube por encima del máximo: **2 minutos de gracia** antes de stop/termination.
- En esos 2 minutos: **shutdown graceful** – guardar datos y **dejar de servir tráfico**.

5.2 Spot Requests

Defines: cantidad de instancias, precio máximo, launch specification (AMI, etc.), y rango de validez (*from/until*, puede ser infinito).

Tipo	Comportamiento
One-time	Se lanza la instancia y el request desaparece
Persistent	Si la instancia se detiene o es interrumpida, el request relanza instancias automáticamente

Orden correcto para terminar Spot Instances (examinable)

1. Primero **cancelas** el spot request.
2. Después **terminas** las instancias.

Si se hace al revés (terminar instancias primero, en modo persistent), el spot request detecta que faltan instancias y **las vuelve a lanzar**. Se puede cancelar un request en estado *open*, *active* o *disabled* (no *failed*, *cancelled* ni *closed*).

5.3 Spot Fleet

- Conjunto de Spot Instances y, opcionalmente, instancias On-Demand.
- Se definen múltiples **launch pools**: distintos instance types, OS, AZs.
- El fleet intenta cumplir el **target capacity** dentro de las restricciones de precio, eligiendo el mejor pool automáticamente.

5.4 Estrategias de asignación de Spot Fleet

Estrategia	Qué hace	Cuándo usarla
lowestPrice	Lanza desde el pool con el precio más bajo	La más popular en el examen; cargas cortas
diversified	Distribuye entre todos los pools definidos	Disponibilidad y cargas largas: si un pool falla, los demás siguen activos
capacityOptimized	Elige el pool con la capacidad óptima disponible	–
priceCapacityOptimized	Primero elige el pool con más capacidad, luego el de menor precio dentro de ese	La mejor opción para la mayoría de las cargas

No confundir

diversified ≠ **capacityOptimized**. Si la pregunta habla de “disponibilidad” y “que el resto del fleet siga si un pool falla” → **diversified**.

6. Trampas de examen

- **Timeout** → Security Group. **Connection refused** → la app, no el Security Group.
- Security Group: solo **allow**, nunca deny. Todo el inbound bloqueado por defecto, todo el outbound permitido por defecto.
- Referenciar Security Groups: la regla **inbound** va en quien **recibe** la conexión, no en quien la inicia.
- **Memory Optimized** (RAM) vs. **Storage Optimized** (disco local) – no confundir.
- **Dedicated Host**: compliance y BYOL. **Dedicated Instance**: sin visibilidad de hardware.
- **Capacity Reservation**: se cobra aunque no se use, sin descuento propio.
- Terminar Spot: **cancelar el request primero**, terminar instancias después.
- Spot Fleet: **diversified** = disponibilidad/varios pools. **lowestPrice** = cargas cortas y precio.
- User Data: corre **una sola vez**, como **root**.

7. Tus puntos débiles (repasar en Anki)

1. **Security Groups**: dirección del tráfico (quién bloquea vs. quién recibe, inbound vs. outbound) – tu punto más débil del bloque.
2. **User Data**: corre una sola vez, como root/con sudo.
3. **Dedicated Host**: casos de uso son compliance y BYOL, no “escalar recursos”.
4. **Spot Fleet strategies**: diversified = disponibilidad/pools distribuidos; lowestPrice = cargas cortas; capacityOptimized $\neq$ diversified.
5. En preguntas de **contraste** (“cuál es la diferencia con...”), desarrollar el por qué, no solo dar la respuesta correcta.
6. En preguntas de **caso de uso específico**, recordar el ejemplo textual de la lección en vez de inventar uno propio.

Puntaje EC2 Fundamentals

Bloque	Puntaje
1. EC2 Basics	2.3/3
2. Security Groups & Ports	1.7/3
3. Instance Types	2.5/3
4. Purchasing Options	3.8/5
5. Spot Instances & Spot Fleet	2.8/4
Total EC2 Fundamentals	13.1/18 (73 %)

8. Vocabulario en inglés para tus respuestas

Inglés	Nota
<i>network card / network interface</i>	no decir “red card” (calco de “red” = network en español)
<i>inbound / outbound</i>	no decir “input” ni “onbound”
<i>to cancel a (spot) request</i>	<i>cancel</i> , no <i>stop</i> , para requests
<i>to stop / terminate an instance</i>	<i>stop</i> o <i>terminate</i> , para instancias
<i>to reference security groups</i>	no “connect security groups”
<i>cheaper than</i>	con adjetivos cortos: <i>-er</i> , no <i>more</i>
<i>at any time</i>	no “in any moment”
<i>it depends on</i>	recuerda la preposición <i>on</i>
<i>budget</i>	no “presupuesto” en medio de una frase en inglés
<i>gracefully shut down</i>	guardar datos y dejar de servir tráfico

Ultra-resumen (léelo antes de dormir)

EC2 = cómputo bajo demanda. **User Data** corre una vez, como root. **Security Groups** solo permiten (allow), inbound bloqueado por defecto, outbound permitido por defecto; timeout = SG, connection refused = la app. **Instance types**: clase + generación + tamaño; General Purpose, Compute (C), Memory (R, RAM), Storage (I/D/H1, disco). **Compra**: On-Demand (flexible), Reserved/Savings Plans (steady-state, descuento), Spot (barato pero interrumpible), Dedicated Host (compliance/BYOL), Capacity Reservation (se cobra igual, sin descuento). **Spot**: 2 minutos de gracia, cancelar el request antes de terminar instancias, diversified para disponibilidad.